Identification et classification de sous-types de lymphocytes T CD8+ cytotoxiques à partir de données single-cell RNA-seq par machine learning

Contexte :

Le corps humain possède un système immunitaire permettant de protéger l'organisme des agents pathogènes. Une partie de ce système immunitaire possède des cellules appelées des lymphocytes T, il y en a de deux types : les lymphocytes T CD8+ (cytotoxique) et les lymphocytes T CD4+ (helper). Nous allons étudier les lymphocytes CD8+, en manipulant les résultats d'un séquençage en cellule unique de ces cellules. Le fichier manipulé ressemble à un tableau avec une ligne par cellule, et un gène par colonne, ce qui permet de voir à quel point chaque gène est exprimé dans chaque cellule. Ce qu'il faut savoir c'est que parmi les cellules T CD8+ il en existe de plusieurs sortes, en fonction de leur stade de vie. Ici on étudiera les lymphocytes CD8+ Tcm/Naive, des cellules jeunes/naïves, les Tem/Trm, des cellules CD8+ active, et les Tem/Temra, des cellules aussi actives, mais plus agés.

Puisque ces 3 types se ressemblent beaucoup biologiquement, l'objectif est de trouver quels gènes permettent de les distinguer et d'entraîner des algorithmes de machine learning capables de les classifier automatiquement.

Prise en main du jeu de donnée :

Le jeu de donnée provient du site suivant : CD8+ T cells of Healthy Donor 3 | 10x Genomics, qui regroupe plusieurs jeux de données de séquençage en cellule unique. Ce dernier contient les résultats de ce séquençage sur les cellules CD8+ d'une personne en bonne santé.

Avant tout traitement le jeu de donnée contient 54137 cellules exprimés en fonction de 33 538 gènes. Le nombre de gènes est énorme, puisque les données brutes sortent d'une machine qui traitent toute sorte de cellules. On peut commencer à retirer tous les gènes exprimés dans aucune de nos cellules, puisque ces variables n'apportent aucune information. Pour enlever un peu plus de gènes, j'ai choisi de retirer les gènes apparaissant dans moins de 100 cellules, car si tel est le cas, alors le gène est présent dans seulement moins de 0.002% des cellules, donc ces gènes ne seront pas déterminants dans la suite de l'étude, et cela nous permet d'économiser beaucoup de puissance de calcul.

Après ce traitement il nous reste 12 718 gènes, comme variables explicatives.

```
Dimensions avant filtrage : (54137, 33538)
Dimensions après filtrage : (54137, 12718)
```

Fig. 1. Sortie du script du premier filtrage

On peut également vérifier s'il y a des valeurs manquantes, mais le jeu de données provient des sorties de machine ne pouvant pas avoir de valeurs manquantes (soit le gène

est détecté soit on met un 0). Après une vérification rapide on s'aperçoit bien que notre jeu de données ne contienne aucune donnée manquante. Cependant on remarque que notre jeu de donnée est constitué à 90% de 0. Cela est normal avec ce type de jeu de donnée. En effet, les données de single cell RNA seq prennent une « capture » des gènes des cellules à un moment précis, il est probable que ce moment ne capture pas tous les gènes exprimés dans la cellule.

```
-> Aucune donnée manquante dans les métadonnées.
-> Sparsité de la matrice génétique : 90.00% de zéros.
```

Fig. 2. Sortie script identification valeurs manquantes et sparsité

Comme expliqué précédemment, le jeu de donnée initial ne contient seulement que la sortie du séquençage, c'est-à-dire le numéro des cellules en fonction des noms des gènes. Le souci est que on ne connait pas le type de chaque cellule (Tcm/Naive, Tem/Trm ou Tem/Temra) que l'on veut étudier, ce qui est essentiel pour notre analyse.

Pour ça il existe des outils, comme CellTypist, qui étiquette les cellules à l'aide d'une méthode régression logistique avancée.

À l'aide de ces outils j'ai donc étiqueté mon jeu de données, ce qui donne ces résultats :

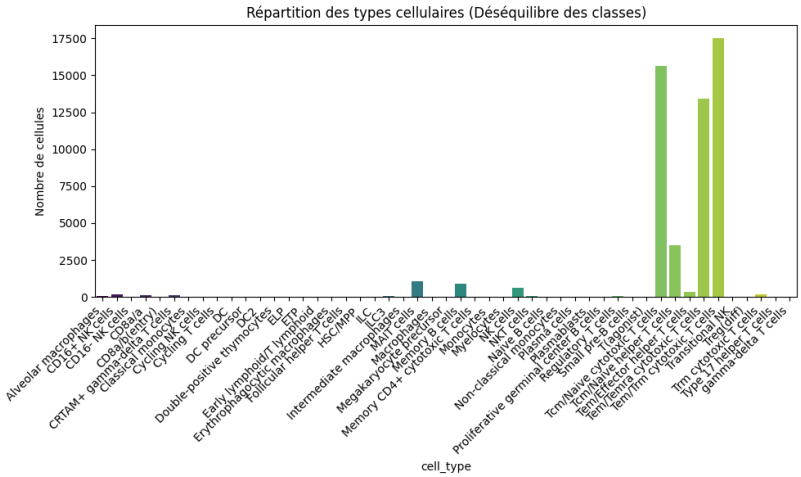

Fig. 3. Répartition après étiquetage

Nous travaillons sur des cellules CD8+, aussi appelé cytotoxique, mais on voit que l'étiquetage à identifier des cellules de notre jeu de donnée qui sont des cellules différentes. On observe des cellules : « T helper », « NK », « mémoire B » etc…

Etant donné que notre jeu de donnée est censé avoir seulement des cellules cytotoxiques, on considère les autres comme des erreurs dû à la ressemblance entre toutes ces cellules immunitaires. Dans ce cadre on ne va garder que les cellules qui ont été étiqueté comme :

- Tem/Trm cytotoxic T cells
- Tcm/Naive cytotoxic T cells
- Tem/Temra cytotoxic T cells

```
Nouvelles dimensions après filtrage : (46578, 12718)

Vérification des classes restantes :
cell_type
Tem/Trm cytotoxic T cells      17537
Tcm/Naive cytotoxic T cells    15619
Tem/Temra cytotoxic T cells    13422
Name: count, dtype: int64
```

Fig. 4. Répartition des classes d'intérêt

Après avoir gardé les classes d'intérêt on observe une répartition assez bonne, ce qui nous évitera d'utiliser des méthodes d'équilibrage (SMOTE) pour la suite.

Méthodes non supervisées :

Maintenant que l'on a un jeu de données propre et utilisable, on peut commencer à appliquer des méthodes de clustering. Les milliers de gènes nous oblige cependant à appliquer des méthodes de réduction de dimension avant cela. On utilisera 3 méthodes : La PCA, l'UMAP et le t-SNE. Ensuite pour évaluer le clustering, on pourra observer les figures en rajoutant les étiquettes et voir si les chaque type de cellule est bien séparé, et on regardera plusieurs métriques calculées à l'aide la méthode de clustering des k-moyennes.

Voici d'abord les résultats en projetant nos cellules sur les 2 composantes principales calculés par les méthodes de réduction de dimension :

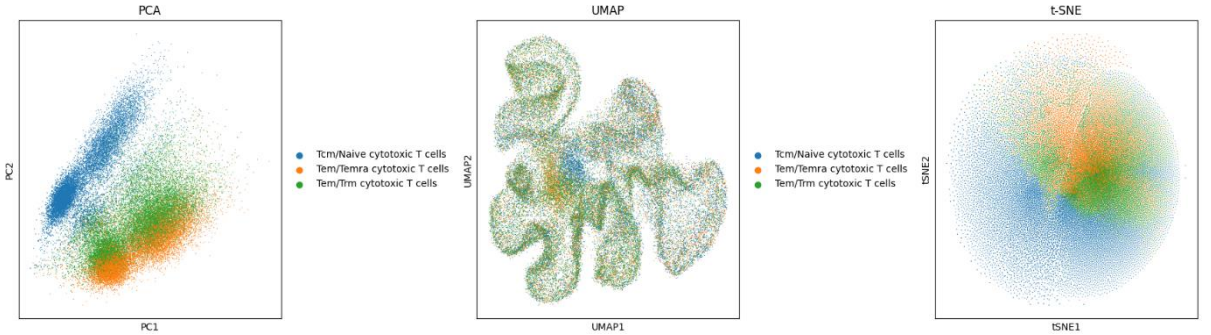

Fig. 5. Répartition des classes d'intérêt

Les résultats qu'on obtient visuellement nous montre que la PCA est la méthode qui discrimine le mieux les différents type de lymphocytes. Mais il faut maintenant utiliser la méthode de clustering cité précédemment pour calculé la Silhouette, ARI et NMI, afin de confirmer nos hypothèses visuelles.

Le coefficient de Silhouhette est proche 1 si chaque point est bien classé, c'est-à-dire si il est plus proche de son cluster et d'un autre. La métrique ARI permet de savoir a quel point les points d'un même cluster sont proches. Quant au NMI il va comparer les clusters créés et nos étuiquettes, et voir à quel point ils sont identiques.

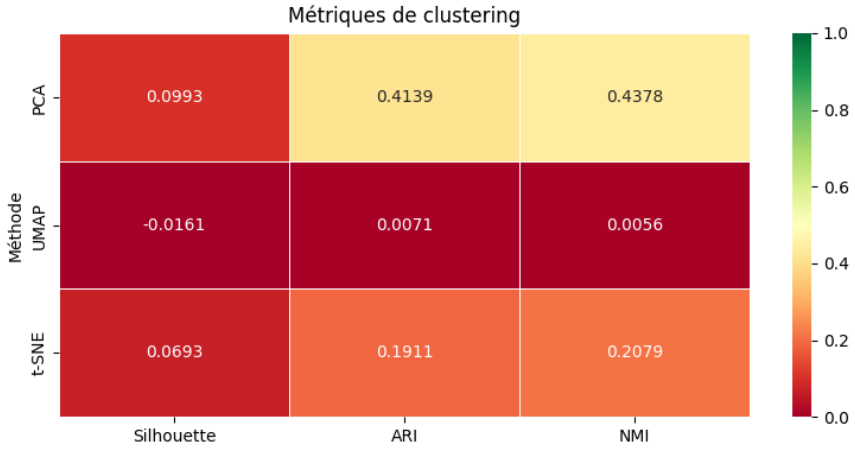

Fig. 6. Métriques de clustering

Les métriques confirment nos observations : la PCA permet d'obtenir les meilleurs résultats pour chaque critère d'évaluation. Cela démontre que les composantes principales parviennent à capturer l'essentiel de la variance biologique liée aux types cellulaires, tout en réduisant la complexité initiale des milliers de gènes.

Pour voir quelle composante gardée on peut utiliser un affichage 3D (l'affichage 3D a été fait avec les composantes principales de la PCA mais avec les fonctions d'affichage de l'UMAP) :

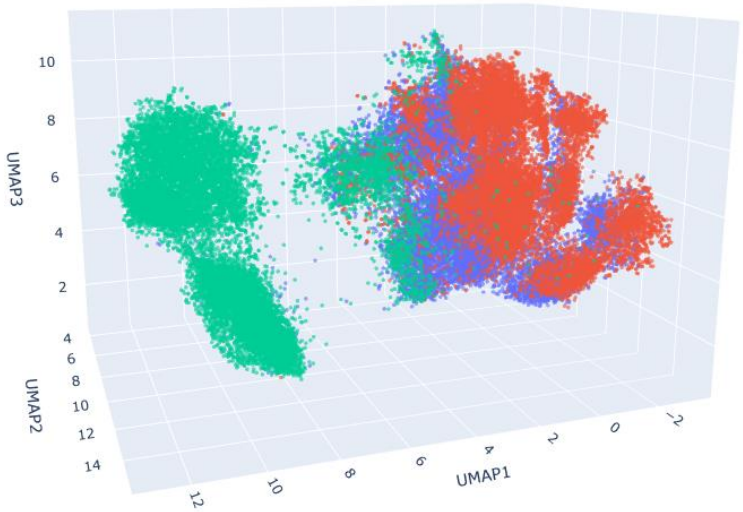

Fig. 7. Projection 3D de la PCA

En manipulant la figure 3D on observe que la PCA permet bien de séparer les différentes classes. Les 2 classes proches sont celles correspondant au lymphocytes actifs (Tem/Trm ou Tem/Temra) et le vert au lymphocyte au repos (Tcm/Naive), c'est donc totalement normal que les 2 groupes actifs se touchent, et c'est ce qui expliquent les scores très bas pour la métrique « silhouette ».

Sur la figure 3D on observe que c'est la première composante principale de l'ACP qui sépare le plus mais on peut confirmer ce constat avec le graphique suivant :

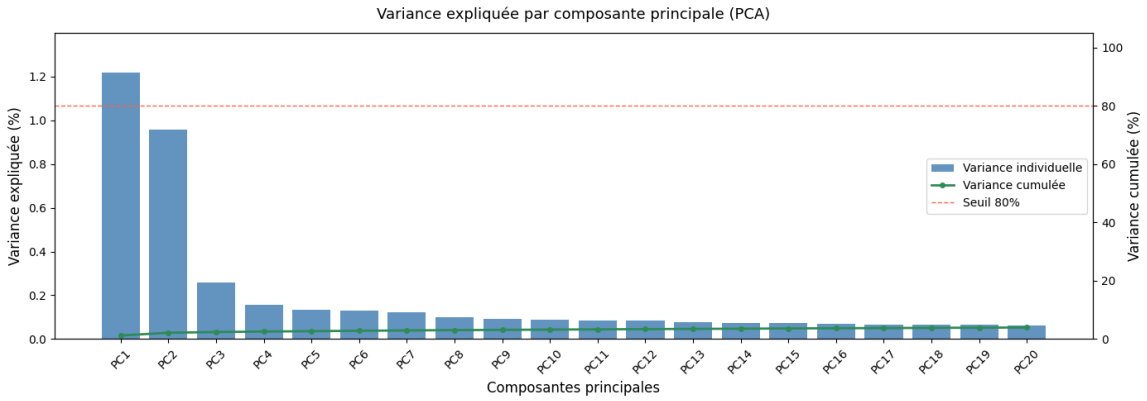

Fig. 8. Variable expliquée par les composantes de la PCA

Ce graphique est intéressant puisqu'il nous permet de voir que les composantes principales qui expliquent le plus les variances sont les 2 premières, cependant elles expliquent seulement 2.2% à elle deux cumulées. Les 20 premières expliquent à peine 5% de la variance. Ce résultat est logique, puisque les cellules étudiées sont toutes très proche il est donc difficile de trouver des gènes « évident » qui les séparent. Mais l'étude de PC1 et PC2 va nous permettre de repérer les gènes qui permettent d'expliquer le peu de variance que l'on arrive à expliquer.

Pour la suite de l'étude on se concentrera donc sur les axes de l'ACP, ce qui nous arrange puisqu'aucune étude de corrélation a été faite jusqu'ici, car il n'est pas possible de choisir les gènes à étudier parmi les milliers que l'on a. En se basant sur l'ACP on a des variables orthogonales.

Comme dit plus tôt, l'étude des gènes qui participent à la construction des composantes principales peut nous permettre de mettre en évidence les gènes les plus intéressant à observer pour différencier les cellules CD8+ entre elles. Pour ça on peut notamment afficher les 3 gènes qui construisent le plus nos composantes principales.

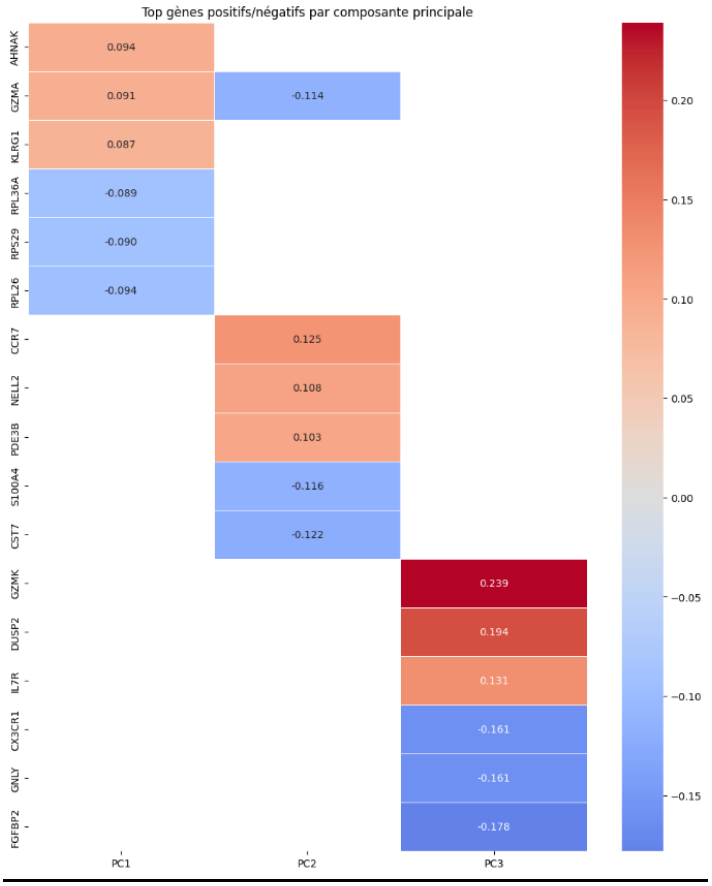

Fig. 9. Gènes qui participent le plus à la construction des PC

Les gènes qui participent le plus à la construction des 2 premiers axes sont les gènes suivants : AHNAK, GZMA, RPL26, RPS29, CCR7, NELL2, CST7, S100A4.

Selon les recherches de Galetti & al en 2020 (1) et de Matza et al. (2) qui ont réalisé des études plus générales, les gènes qui devraient être les plus intéressant pour distinguer les CD8+ seraient les gènes : AHNAK, HNRNPLL, GZMK, GZMM, IFNG, CCL4, CCL5, GZMB, GNLY, NKG7, ZEB2 et GZMA.

Le gène GZMA est bien présent dans les deux premières composantes principales, tandis que AHNAK est seulement présent dans la première. GZMK et GNLY sont présents dans la 3 ème composante principale. Les différences entre les gènes trouvés et les gènes de la littérature peuvent s'expliquer par plusieurs raisons. Tout d'abord les gènes que l'ont a trouvé ne sont pas absent de la littérature, mais leur présence dans les différents types de lymphocytes est très peu documentée, mais on peut confirmer qu'ils ont tous un rôle précis. Ensuite si les gènes sont très corrélés entre eux alors la PCA n'a pas besoin d'utiliser chacun de ces gènes s'ils amènent tous la même information. Pour vérifier cela on peut tracer la matrice de corrélation avec les gènes de l'article.

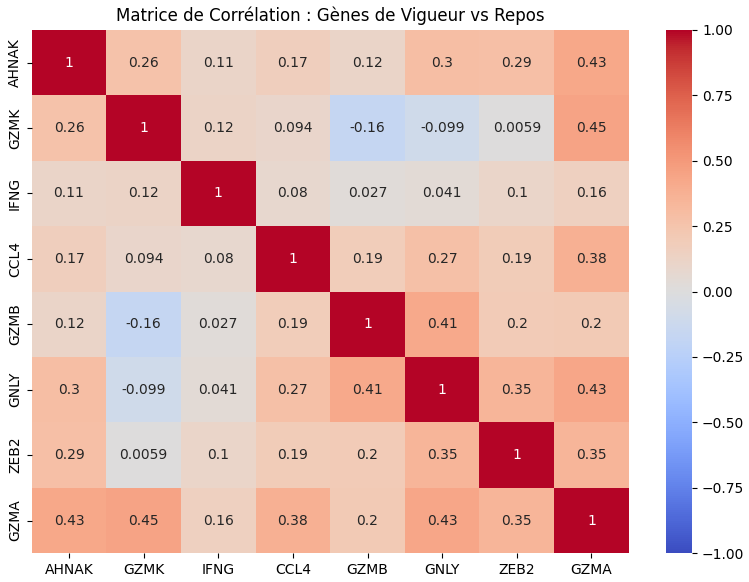

Fig. 10. Corrélation gènes de la littérature

La matrice de corrélation nous montre bien que plusieurs gènes sont corrélés entre eux. Notamment GZMA qui possède une corrélation non négligeable avec plusieurs gènes, ce qui pourrait expliquer que l'on ne les retrouve pas dans la construction des composantes principales de la PCA.

Enfin la dernière raison qui pourrait expliquer la différence entre nos gènes de la PCA et les gènes de l'article est l'homogénéité que l'on voit dans la heatmap (Fig. 9.). En effet il n'y a pas un ou deux gènes qui résume toutes les composantes principales, tous les gènes apportent ont un poids équivalent dans la construction des composantes, les 6 gènes qui apportent (positif et négatif) le plus dans la première composante, sont tous entre 0.087 et 0.094. On peut en déduire qu'énormément de gènes participent à la construction des composantes avec un poids homogènes entre tous ces gènes. Pour vérifier ça on pourrait afficher les 15 gènes qui participent le plus à la construction de chaque axe. Cependant, que l'on trouve ou pas les gènes de la littérature cela ne changerait pas grand-chose pour notre étude. La conclusion que l'on peut faire pour le moment est que les composantes principales qui permettent de séparer nos groupes sont construits à partir de nombreux gènes, et qu'il n'y a pas un petit groupe de gènes qui résume la variance entre les clusters.

Méthodes supervisées :

Les méthodes supervisées que l'on va mettre en place permettent de prédire le type de lymphocytes grâce aux gènes exprimés dans ce dernier. On construit ces méthodes à l'aide des annotations que l'on a créées plus tôt. Parmi toutes les méthodes qui existent, on va en tester 3 types : L'arbre de décision, Random Forest et XGboost. Il a été choisi de faire un arbre de décision, car c'est la méthode la plus interprétable cliniquement, avec un arbre unique qui va commencer par le gène le plus discriminant et affiner la recherche avec des gènes plus précis. Random Forest et XGboost sont 2 méthodes qui sont beaucoup plus robustes au bruit, ce qui est quelque chose de très important avec notre jeu de donnée rempli de 0.

Ces 3 méthodes possèdent plusieurs paramètres à régler, il y aura donc plusieurs tentatives pour tester quels sont les meilleurs paramètres. Cependant, cela est très coûteux en ressources de calcul, notamment avec les milliers de gènes sur lesquels on travaille. On ne peut donc pas directement appliquer ces méthodes (surtout Random forest et XGboost) sur les gènes, car le matériel ne supporte pas la puissance de calcul demandé. À la place, on appliquera d'abord les méthodes sur les composantes créées par la PCA, étant donné que la PCA a eu de bons résultats, puis avec les meilleurs paramètres calculés avec la PCA, on lancera les méthodes sur les gènes, pour que les méthodes ne tournent qu'une seule fois. Ce n'est pas idéal car les méthodes avec les gènes pourraient avoir des paramètres idéaux légèrement différents, cependant étant donné que notre PCA à particulièrement bien discriminer, notre choix est le bon compromis entre performance et temps/puissance de calcul.

Arbre de décision

Voici ce que l'on obtient en premier lieu en appliquant les PC de la PCA pour créer notre arbre de décision.

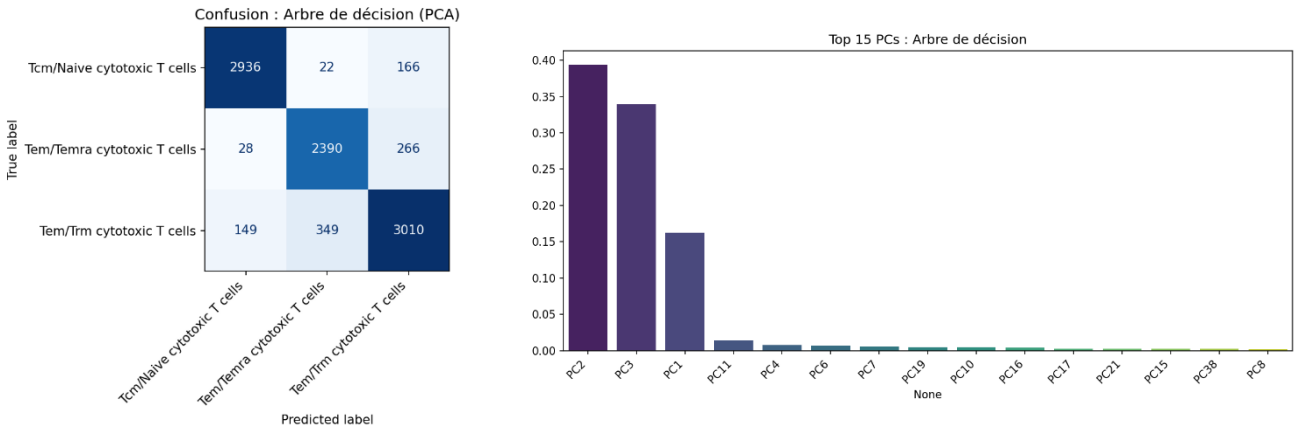

Fig. 11. Matrice de confusion et les variables que diminue le plus l'indice de Gini - Arbre de décision avec la PCA

La matrice de confusion de l'arbre de décision avec la PCA montre que l'arbre classe correctement la majorité des cellules pour chaque type de lymphocyte. Pour plus de précision il faudrait regarder les métriques associées à la prédiction, mais on observera ça après chaque méthode. En regardant le diagramme on s'aperçoit que, contrairement à la PCA qui identifie PC1 comme la composante expliquant le plus de variance, l'arbre de décision utilise davantage PC2 et PC3 comme critères discriminants. Cela s'explique par le fait que la variance maximale (PC1) ne correspond pas nécessairement à la meilleure séparation entre les 3 sous-types. PC2 et PC3 capturent des variations plus spécifiques aux différences biologiques entre Naive, Tem/Trm et Tem/Temra.

Ce premier arbre de décision a permis de trouver les meilleurs paramètres pour notre arbre, pour trouver les meilleurs paramètres on a garder ceux qui maximisent la F1-macro. Etant donné que dans mon jeu de donné je n'ai pas d'étiquette plus importante que d'autres (contrairement des échantillons malade/non malades), c'est la meilleure métrique à regarder.

Avec ces paramètres on recrée un arbre de décision sur les tous les gènes :

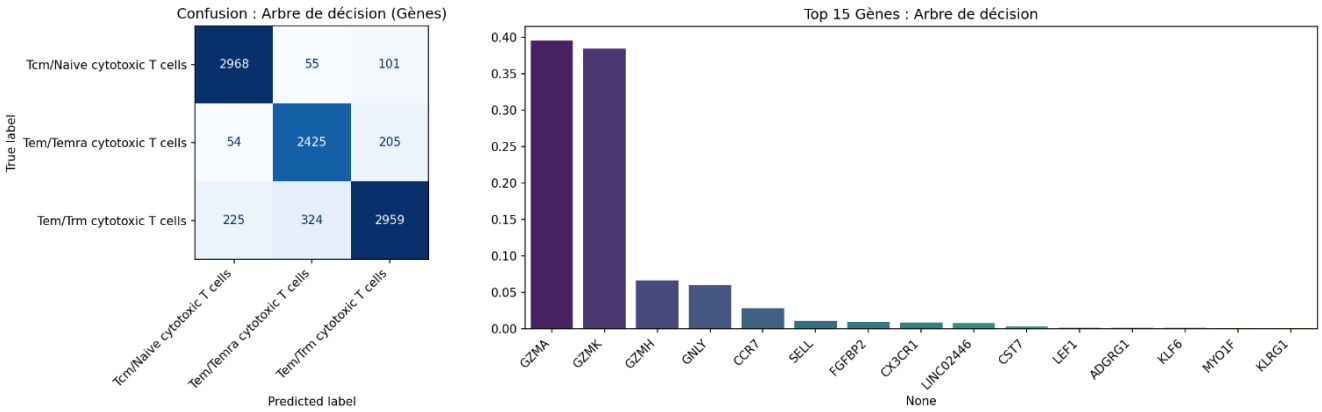

Fig. 12. Matrice de confusion et les variables que diminue le plus l'indice de Gini - Arbre de décision avec les gènes

La matrice de confusion est assez similaire à celle de l'arbre de décision avec la PCA. Les gènes qui ressortent sont intéressants à observer puisque les 4 premiers font partis de ceux qui ont été listé dans la littérature, et sont assez différents de ceux qui ont été utilisé pour construire les axes de la PCA (Fig. 9). De plus, il y a deux gènes qui sont beaucoup plus important que les autres, tandis que pour les axes il n'y avait pas de gènes prédominant par rapport aux autres. Cela renforce les résultats de l'arbre précédent, car encore une fois avec l'arbre de décision on obtient des variables explicatives différentes que lors de la réduction de dimensionalité. En somme, les variables qui expliquent la variance maximale ne sont pas les même que ceux pour capture les variations qui nous permettent de classifier.

Random Forest

On passe maintenant au Random Forest avec les axes de la PCA.

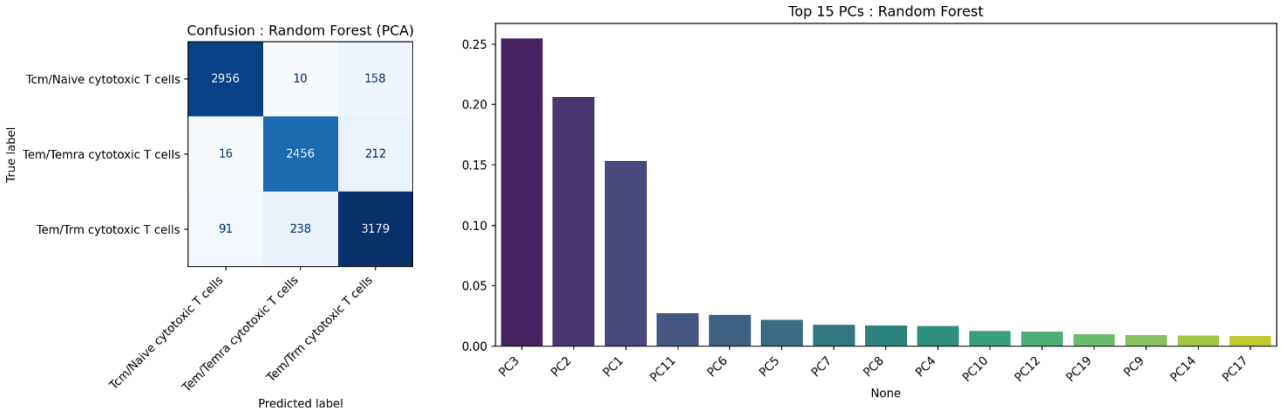

Fig. 13. Matrice de confusion et les variables que diminue le plus l'indice de Gini – Random Forest avec la PCA

La matrice de confusion est similaire à celles des arbres de décisions. Le diagramme montre la même conclusion que pour l'arbre de décision avec la PCA, PC2 et PC3 sont les plus utilisés comme caractère discriminants, PC3 surpasse même PC2. Cependant le Random Forest utilise davantage les autres composantes, notamment PC1 qui est nettement plus proche de PC2.

On reprend maintenant les paramètres trouvés pour ce Random Forest pour créer une méthode Random Forest, avec cette fois ci les gènes comme variables discriminantes.

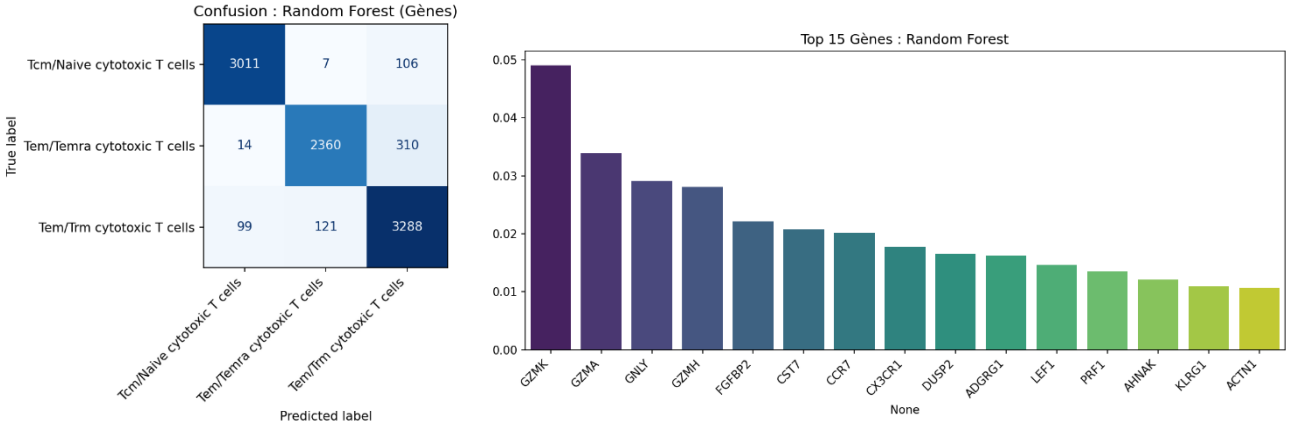

Fig. 14. Matrice de confusion et les variables que diminue le plus l'indice de Gini – Random Forest avec les gènes

La matrice de confusion à l'air légèrement meilleur pour la plupart de la classification. Le diagramme montre encore une fois qu'il y a moins de variables qui dominent les autres pour la discrimination. Les 4 premiers gènes sont les même que l'on retrouve avec l'arbre de décision (Fig. 12), et ceux de la littérature.

XGBoost

On passe maintenant au XGBoost avec les axes de la PCA.

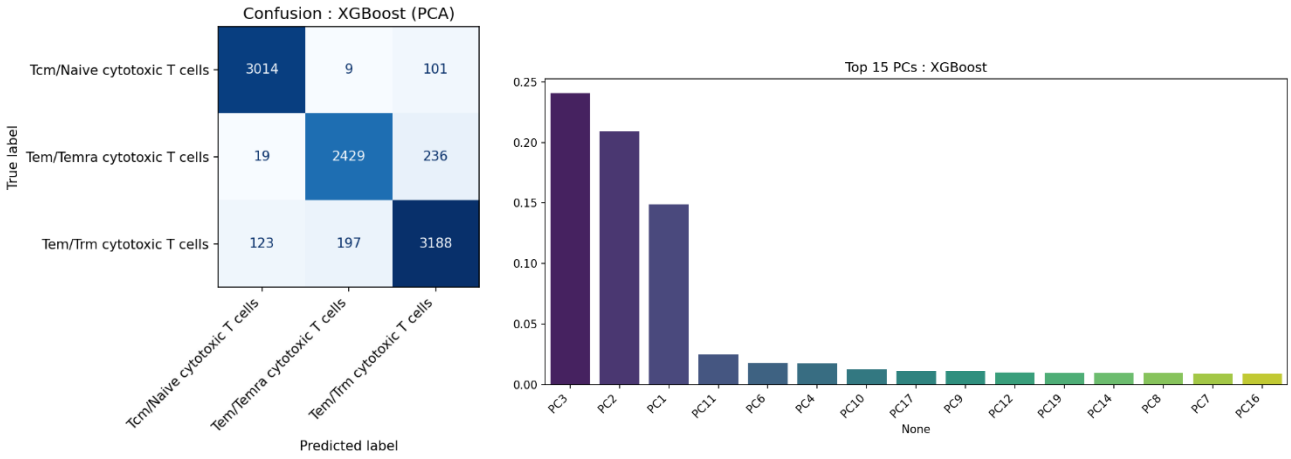

Fig. 15. Matrice de confusion et les variables que diminue le plus l'indice de Gini – XGBoost avec la PCA

La matrice de confusion nous montre que la méthode arrive, encore une fois, à bien discriminer chaque type de lymphocytes. Le diagramme est très ressemblant au Random Forest avec PCA, c'est-à-dire que les 3 axes dominants sont PC3, PC2 et PC1, toujours dans l'ordre inverse que ce qui avait été trouvé pour la PCA.

On reprend maintenant les paramètres trouvés pour ce XGBoost pour créer une méthode XGBoost, avec cette fois ci les gènes comme variables discriminantes.

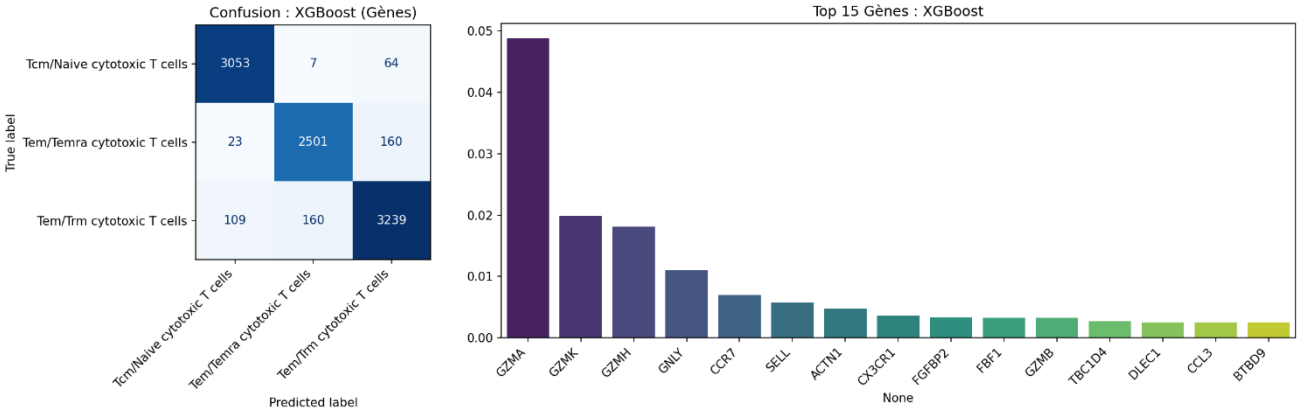

Fig. 16. Matrice de confusion et les variables que diminue le plus l'indice de Gini – XGBoost avec les gènes

La matrice de confusion montre un meilleur modèle que celui avec les PCA. Le diagramme est assez différent des modèles construits avec les gènes. En effet, ici le gène GZMA est celui qui discrimine le plus, presque deux fois plus que le gène GZMK deuxième dans la liste.

Comparaison

Comme expliqué plus tôt, dans notre contexte on n'a pas besoin de prioriser les bons résultats d'une classe ou d'une autre. C'est-à-dire qu'il n'y a pas besoin de choisir entre rappel et précision. Dans notre cas on va se concentrer sur une métrique qui prend en compte le rappel et la précision : la F1-Score.

Dans le tableau suivant on retrouve tout de même toutes ces métriques afin de pouvoir comparer si deux méthodes on une F1 score similaire.

Fig. 17. F1-Score, précision et rappel de chaque méthode utilisée

Toutes les métriques montrent que le modèle qui discrimine le mieux les types de cellules CD8+, est le modèle XGBoost sur les gènes. D'une manière général tous les modèles sont assez bons et on pourrait privilégier l'arbre de décision sur les gènes pour avoir un modèle interprétable. Le tableau nous montre également que les modèles qui se basent directement sur les gènes sont tous plus performant que les modèles qui se basent sur les axes de la PCA.

Limites :

Les limites des méthodes sont multiples. Tout d'abord, notre fichier initial a pu contenir des erreurs de laboratoire, ce qui a pu mener à avoir autre chose que des cellules T CD8+. Ensuite toute l'analyse se base sur l'étiquetage avec une méthode de régression logistique, comme chaque méthode cette régression a surement pu mal étiqueter certaines cellules.

1. Galletti, G., De Simone, G., Mazza, E. M. C., Puccio, S., Mezzanotte, C., Bi, T. M., Davydov, A. N., Metsger, M., Scamardella, E., Alvisi, G., De Paoli, F., Zanon, V., Scarpa, A., Camisa, B., Colombo, F. S., Anselmo, A., Peano, C., Polletti, S., Mavilio, D.,. . . Lugli, E. (2020). Two subsets of stem-like CD8+ memory T cell progenitors with distinct fate commitments in humans. *Nature Immunology*, *21*(12), 1552-1562. https://doi.org/10.1038/s41590-020-0791-5

2. Matza, D., Badou, A., Jha, M. K., Willinger, T., Antov, A., Sanjabi, S., Kobayashi, K. S., Marchesi, V. T., & Flavell, R. A. (2009). Requirement for AHNAK1-mediated calcium signaling during T lymphocyte cytolysis. Proceedings Of The National Academy Of Sciences, 106(24), 9785-9790. https://doi.org/10.1073/pnas.0902844106